

RAFAELA SOUSA DE ALENCAR LACERDA

**Estratégias de controle distribuído para sistemas de armazenamento em
baterias para regulação de tensão em redes de distribuição com alta
penetração de geração fotovoltaica**

R1.1: Revisão Bibliográfica - Controle Distribuído


Orientador: Prof. Dr. Juan Carlos Cebrian

São Paulo
2026

1. INTRODUÇÃO AOS MÉTODOS DE CONTROLE

De forma geral, existem quatro arquiteturas utilizadas para o gerenciamento e controle de Sistemas de Armazenamento de Energia em Baterias (BESS): local, descentralizado, centralizado e distribuído [1]**Error! Reference source not found..** No controle local, cada banco de baterias conta com um Sistema de Gerenciamento de Energia (EMS) autônomo, que atua com base em medições locais (Figura 1 a). No controle descentralizado, um supervisor gerencia partes ou zonas específicas da rede (Figura 1 b), enquanto no controle centralizado, um único ponto de controle monitora e despacha ações para toda a rede (Figura 1 c). Já no controle distribuído, não há controlador central: cada BESS se comunica com seus vizinhos para trocar informações e tomar decisões de forma coordenada (Figura 1 d).

Figura 1: Diagrama de rede de distribuição com controle a) local, b) descentralizado, c) centralizado, d) distribuído. Adaptado de [1].



Nesse contexto, a aplicação do controle distribuído traz benefícios em relação às outras estratégias de controle. Ele demonstra resiliência e robustez [10], uma vez que a falha de um nó não compromete todo o sistema, ao contrário do controle centralizado; escalabilidade [10] [12], já que novos BESS podem ser adicionados à rede sem reconfigurar a arquitetura de controle; latência reduzida [11], por meio das

decisões locais rápidas, para respostas a transitórios e variações rápidas de frequência/tensão; e infraestrutura de comunicação entre nós vizinhos mais simples que a necessária para estratégias centralizadas [12]. Assim, o controle centralizado tem menor custo de infraestrutura de comunicação e supervisão centralizada e facilita modelos de negócio descentralizados, como a geração distribuída. Por outro lado, uma das principais desvantagens de empregar o controle distribuído é que a coordenação global ótima pode não ser atingida, uma vez que essa estratégia não permite visão completa da rede de distribuição.

2. ANÁLISE DOS ARTIGOS SELECIONADOS

No contexto de controle distribuído, existem na literatura diversas formulações matemáticas e algoritmos, dentro eles, é possível destacar o consenso [2][3], ADMM *alternating direction method of multipliers*, ou ADMM [4], *distributed model predictive control*, ou DMPC [5], multi-agent reinforcement learning, ou MARL [6], Controle Estocástico de Dupla Camada [7], Lógica Fuzzy Distribuída [8] e *monte carlo tree search based reinforcement learning*, ou MCTS-RL [9]. A seguir, cada um desses métodos será analisado, com ênfase em suas contribuições e limitações no contexto da proposta de desenvolvimento de um esquema de controle distribuído para sistemas de armazenamento de energia em baterias (BESS), aplicado à regulação de tensão em redes de distribuição com elevada penetração de geração fotovoltaica (FV).

2.1. CONTROLE DISTRIBUÍDO POR CONSENSO

Em [3], o autor propõe um algoritmo de controle distribuído baseado em consenso para mitigar problemas de sobretensão gerados por alta penetração de geração FV em redes de distribuição de baixa tensão, considerando atrasos de comunicação na rede. A estratégia de controle envolvendo ação local e consenso distribuído baseia-se no princípio de que a regulação deve operar acoplada à capacidade máxima de cada BESS ($P_{i,max}$) de injetar ou absorver potência, determinada em função do seu Estado de Carga (SoC) e pelo requisito de regulação de tensão. A arquitetura de controle é dividida em etapas complementares:

- Etapa 1: Ação local (*droop*): inicialmente, calcula-se a potência ideal ($P_{i,droop}$) que cada bateria deveria fornecer/absorver localmente para sanar a violação de tensão da sua barra de conexão com a rede elétrica.

- Etapa 2: Algoritmo de consenso: comunicando-se apenas com agentes vizinhos, o sistema executa um algoritmo iterativo para estimar duas médias globais: a média ($P_{d,avg}$) da potência *droop* ($P_{i,droop}$) exigida pela rede para regular a tensão localmente e a média ($P_{m,avg}$) das capacidades máximas de injetar/absorver potência ($P_{i,max}$) de todos os BESS.
- Etapa 3: Despacho proporcional: por fim, a potência de saída de cada BESS (P_i) é calculada pela razão dessas variáveis: $P_i = P_{i,max} * (P_{d,avg} / P_{m,avg})$, garantindo o compartilhamento do esforço de regulação de tensão.

Nos estudos de caso, compara-se os resultados entre regulação de tensão por BESS, com controle *droop* e com controle distribuído por consenso. Com isso, as tensões nas barras sem regulação passam do limite estabelecido de $\pm 5\%$ do valor nominal, enquanto tanto com controle *droop* quanto com consenso, as tensões permaneceram dentro dos limites, sem grandes diferenças percentuais entre si. Porém, em relação à potência injetada/absorvida pelos BESS, entre esses dois tipos de controle, apenas o consenso realmente distribui o esforço de regulação, uma vez que nenhum BESS apresentou potência de saída zero. Apesar do método proposto em [3] ter sido aplicado a uma rede de distribuição de baixa tensão, em que a relação X/R é pequena, a estratégia de controle distribuído por consenso pode ser aplicada a redes de média tensão.

2.2. OTIMIZAÇÃO DISTRIBUÍDA VIA ADMM

Em [4], o autor propõe um esquema de controle distribuído multi-agente voltado para a regulação de tensão em redes de distribuição modernas com alta penetração de recursos energéticos distribuídos (DERs). A abordagem visa solucionar as violações de tensão (sobretensão e subtensão) causadas pela geração intermitente dos sistemas fotovoltaicos (FV) e as variações na demanda de carga. O problema de regulação de tensão baseado em um sistema centralizado é formulado com uma função objetivo (*objective function*) que busca minimizar os custos associados às variações na potência ativa e reativa dos inversores fotovoltaicos, mantendo as tensões nodais dentro dos limites estabelecidos. Para viabilizar a resolução de forma distribuída, a relação não-linear do fluxo de potência é contornada utilizando uma aproximação linear de primeira ordem baseada em matrizes de sensibilidade de tensão.

A decomposição do problema centralizado em múltiplos subproblemas locais é realizada através do algoritmo Proximal Jacobian Alternating Direction Method of Multipliers (PJ-ADMM). Esse método se destaca por permitir que o problema seja resolvido de forma paralela e distribuída por cada agente (inversor inteligente), reduzindo o peso da comunicação na rede. Uma das maiores contribuições do artigo é a coordenação estruturada em duas fases para otimizar o uso do BESS sem desperdiçar a energia FV gerada. Na fase 1, o algoritmo calcula o corte mínimo de potência ativa (*curtailment*) necessário para mitigar as sobretensões, além do suporte de reativos. Na fase 2, em vez de simplesmente descartar a energia, a potência ativa cortada virtualmente na Fase 1 é redirecionada para definir a potência de carregamento do BESS. Assim, o dimensionamento e o acionamento do BESS emergem da própria estratégia de *curtailment* virtual. O modelo respeita as restrições físicas das baterias (limites de energia e potência) e promove a redução das perdas de potência ativa na rede, uma vez que o BESS absorve o excesso de geração ao meio-dia e descarrega durante os picos de demanda noturnos.

Para analisar a performance do algoritmo proposto e comprovar sua eficácia e escalabilidade, simulações foram conduzidas em três redes IEEE (13, 33 e 141 barras). Na rede IEEE 13 barras, o cenário que combinou o controle de potência ativa e reativa (Cenário IV) apresentou o melhor desempenho, mitigando as violações de tensão com um corte de apenas 1,3% de potência ativa e 3% kVAr de suporte reativo durante o meio-dia, horário crítico para geração FV, convergindo em menos de 10 iterações. Na rede IEEE 33 barras, foram instaladas 20 unidades FV e 4 BESS e, novamente, o método mitigou as violações e reduziu as perdas de potência ativa. Já na rede IEEE 141 barras, foi analisada a escalabilidade do algoritmo, que convergiu em apenas 14 iterações (0,75 minuto). O aumento substancial no número de agentes na rede não causou um aumento proporcional no número de iterações, mantendo uma taxa de convergência razoável para a operação em tempo real.

2.3. CONTROLE PREDITIVO DMCP

Em [5], o autor aborda o desafio da regulação de tensão em Redes de Distribuição Ativas (ADN) frente à incerteza inerente à geração de Recursos Energéticos Distribuídos (DERs), especificamente sistemas FV. Embora o Controle Preditivo Baseado em Modelo Estocástico (SMPC) seja uma solução conhecida para

lidar com incertezas de previsão, a sua implementação centralizada sofre com pesadas cargas computacionais e de comunicação, além de apresentar vulnerabilidade a falhas de ponto único (falha de comunicação). Para superar essas barreiras, os autores propõem um esquema de Controle Preditivo de Modelo Estocástico Distribuído (DSMPC) em duas etapas.

A primeira etapa é a seleção de cenários de operação. A incerteza da geração FV é modelada assumindo que os erros de previsão seguem uma distribuição normal. A partir desse modelo, o método Monte Carlo é utilizado para gerar um amplo conjunto de cenários possíveis de saída FV. Para evitar a explosão computacional, aplica-se o método de redução reversa simultânea (*simultaneous backward reduction*) para selecionar apenas os cenários operacionais mais representativos e prováveis.

A segunda etapa é o controle DMPC, em que a rede de distribuição é dividida em Áreas de Controle Local (LCAs) agregando barras próximas. Para cada cenário selecionado na etapa 1, formula-se um problema de otimização cujo objetivo é minimizar os custos das ações de controle, penalizando o uso excessivo de potência reativa dos inversores FV, de potência ativa dos BESS e as violações de tensão (através de variáveis de folga). As equações de fluxo de potência são linearizadas (DistFlow linearizado). Para resolver a otimização de forma distribuída, utiliza-se o método ADMM, onde as LCAs vizinhas trocam apenas informações de fronteira (desvios de tensão e fluxo de potência nas linhas de interligação) até alcançarem um consenso global.

Este algoritmo foi testado por meio de simulação com a rede IEEE 34 barras, que foi particionada em 3 LCAs, contendo 33 inversores FV e 7 BESS. Os resultados demonstraram que o esquema DSMPC conseguiu efetivamente mitigar as violações de tensão causadas pela incerteza da geração FV, mantendo os perfis de tensão dentro dos limites estabelecidos de $[0,95; 1,05]$ pu na grande maioria do tempo. Em comparação com o controle centralizado, os perfis de tensão resultantes foram similares, mas o DSMPC demonstra vantagens adicionais de escalabilidade, flexibilidade e menor dependência de comunicação global. Já na comparação com o controle local *droop*, o método proposto obteve custo econômico total por violação dos limites de tensão significativamente menor, uma vez que reduziu tais violações.

2.4. APRENDIZADO POR REFORÇO PROFUNDO MULTIAGENTE (MARL)

Em [6], o autor propõe um framework de regulação de tensão para redes de distribuição com alta penetração de geração FV baseado em MADRL e livre de modelo, com treinamento centralizado e execução descentralizada. O autor discute como, na literatura, os algoritmos de controle de Reinforcement Learning (RL) são vistos como uma solução para lidar com as incertezas da rede e suposições de modelos, mas, de forma contraditória, usam, na etapa de treinamento, modelos físicos precisos da rede. Assim, esse artigo propõe uma estratégia em duas etapas: identificação do sistema e de regulação de tensão.

O framework de MADRL proposto tem quatro principais componentes:

1. Modelo substituto via SPGP (Processo Pseudo-Gaussiano Esparso) para o modelo físico. Com amostras de medições esparsas (potências ativas e reativas e tensões), o SPGP mapeia a relação complexa não-linear entre injeção de potência e a magnitude da tensão e cumpre a função que um modelo físico da rede cumpriria.
2. Partição da rede em várias sub-regiões, em que o agrupamento é feito com base na distância elétrica, calculada através de matrizes de sensibilidade da tensão em relação às potências ativa e reativa. Após a divisão, cada sub-região atua como um agente inteligente independente no ambiente de aprendizado.
3. Formulação da regulação de tensão de várias sub-regiões como um Jogo de Markov (*Markov Game*).
4. Aplicação do algoritmo MASDAC (*multi-agent soft actor critic*) para resolver o Jogo de Markov.

O método foi testado em redes IEEE modificadas: 123 e 342 barras. Foram feitas comparações com outros tipos de controle e o MADRL demonstrou bons resultados. Destaca-se o teste com BESS incorporado na rede de 123 barras, em que o método MADRL evitou a sobretensão mantendo as ações locais perfeitamente coordenadas. Sua execução descentralizada mitigou os desvios de tensão com eficácia similar à do controle centralizado ideal, eliminando a dependência do modelo exato do sistema e as exigências pesadas de telecomunicação de um controlador central.

2.5. CONTROLE ESTOCÁSTICO DE DUPLA CAMADA

Em [7], o autor propõe, para redes de distribuição com crescente penetração de geração FV, uma estratégia de controle de tensão estocástica dividida em dois níveis. A estratégia coordena a atuação de OLTCs (comutadores de tap sob carga), BESSs e a capacidade de compensação de potência reativa (RPC) dos inversores FV. O problema é dividido em duas etapas temporais e topológicas para reduzir a complexidade e o esforço computacional. Para isso, tanto as equações de fluxo de potência quanto a curva de capacidade dos inversores passam por um processo de linearização. Os dois níveis são descritos a seguir:

- Nível 1 (ajuste de OLTC e agendamento diário de BESS): Esse nível faz o agendamento da posição do tap do OLTC na barra de referência e a operação ótima das baterias para as próximas 24 horas (*day-ahead*). Para lidar com as incertezas relacionadas à geração solar, os autores estimam parâmetros de uma função de distribuição Beta e utilizam o método de simulação Monte Carlo para gerar múltiplos cenários diários de geração FV.
- Nível 2 (compensação de reativos): Para lidar com as violações de tensão em tempo real que não foram mitigadas pelo Nível 1, aplica-se o controle da potência reativa dos inversores FV. A rede de distribuição é submetida a um algoritmo de agrupamento que a divide em partições baseadas na similaridade das características de compensação reativa e em um índice de modularidade. Se houver sobretensão, o controlador identifica a partição mais crítica e comanda os inversores dessa zona a absorverem potência reativa. Se o limite da partição for atingido e o problema persistir, partições vizinhas são iterativamente recrutadas.

O método foi testado em um alimentador de distribuição real de 10 kV e 37 barras, mantendo a tensão dentro da faixa segura predefinida de 0,95 a 1,05 pu, enquanto, no cenário sem controle, houve violação de ambos os limites superior e inferior ao longo do dia.

2.6. LÓGICA FUZZY DISTRIBUÍDA

Em [8], o autor propõe um Controlador Lógico Fuzzy (FLC) baseado em regras, embarcado em BESS, para fornecer suporte coordenado de tensão e frequência (V/f) levando em consideração a degradação da vida útil das baterias, para lidar com

desafios de flutuações de tensão e frequência causadas pela alta penetração de geração FV nas redes de distribuição. A metodologia é composta pelas seguintes etapas interligadas:

- Controlador Lógico Fuzzy (FLC): O controlador recebe como variáveis de entrada o desvio de tensão local (ΔV), o desvio de frequência do sistema (Δf) e o SoC da bateria, e tem como saídas as potências ativas (P) e reativas (Q) normalizadas que o BESS deve injetar ou absorver.
- Regras Fuzzy: Foram desenvolvidas 75 regras lógicas a partir de 6 políticas, com o objetivo de prover suporte de regulação de frequência e tensão. Um exemplo de política é que a frequência é regulada exclusivamente por P, enquanto a tensão pode ser regulada por P ou Q.
- Sistema Multi-Baterias: Para evitar que as baterias alternem rápida e frequentemente entre os modos de carga e descarga (micro-ciclos que degradam a bateria intensamente e reduzem a tempo de vida), os BESSs são divididos em dois grupos: o Grupo A (com SoC baixo) e o Grupo B (com SoC alto). Quando o sistema requer absorção de potência (carga), o Grupo A é acionado, e quando requer injeção (descarga), o Grupo B atua.

Um diferencial desse trabalho é a formulação de um modelo matemático semi-empírico de envelhecimento derivado de um banco de dados real de baterias de Grafite/LiCoO₂ que foram submetidas a ciclos sob cinco cenários diferentes. Esse modelo sugeriu que operar com uma faixa grande de SoC reduz significativamente a expectativa de vida da bateria, e isso foi considerado ao desenvolver as regras fuzzy.

A abordagem foi validada em um sistema de distribuição radial padrão IEEE de 33 barras. O desempenho do FLC proposto foi comparado com duas estratégias clássicas: controle *droop* tradicional (regulando V e f de forma separada) e controle FLC sem levar em conta o SOC da bateria. O método proposto resultou em um desvio de tensão substancialmente menor (8,1% de melhoria) em comparação ao *droop* tradicional, com impacto quase nulo no desvio de frequência (apenas 0,9% de aumento). Em comparação ao método FLC que ignorava o SoC, o sistema conseguiu evitar os eventos prejudiciais de sobrecarga e descarga profunda (que levavam o BESS à exaustão durante a noite). Através do controle consciente do SOC e da arquitetura de sistema multi-baterias, o método proposto reduziu a degradação média das baterias em 80%.

2.7. CONTROLE HEURÍSTICO MCTS-RL

Em [9], os autores propõem o Controle Cooperativo do Estado de Carga (CSOCC) para mitigar violações de tensão em redes de distribuição de baixa e média tensão, causadas pelo carregamento total prematuro dos BESSs durante longos períodos de alta geração. Os autores buscam resolver o problema da capacidade finita das baterias sem precisar superdimensioná-las. Essa estratégia combina duas camadas:

- Controle descentralizado via MPC: Em cada região impactada, um controlador MPC monitora o fluxo de potência reverso e atua localmente mitigando a sobretensão e otimizando os custos de energia do BESS com base nas tarifas. Se a bateria local não for suficiente, o MPC estima a capacidade adicional de bateria que falta para conter o fluxo reverso.
- Planejador centralizado via MCTS-RL: a demanda por capacidade ociosa calculada pelo MPC é enviada a um controlador centralizado operado por Aprendizado por Reforço baseado em Busca em Árvore Monte Carlo (MCTS-RL). O MCTS-RL mapeia a rede e identifica “regiões assistentes”, em que não há violação de tensão, selecionando os melhores nós para receberem a potência excedente calculada pelo MPC.

O método foi testado em uma rede padrão IEEE de 33 barras e em um circuito de distribuição real da cidade de Lloydminster, Alberta, Canadá. Em relação à prevenção de saturação das baterias, o CSOCC conseguiu aumentar virtualmente a capacidade das baterias de regiões críticas, estendendo o esforço de armazenamento para as regiões assistentes. Além disso, manteve a tensão dentro do limite seguro considerado de 1,045 pu (pois a rede é pequena e não atinge o limite comum de 1,05 pu), ao contrário da rede sem controle e BESS. A coordenação econômica feita pelo MPC reduziu de forma significativa o custo total da operação de energia e uso do BESS, quando comparado à operação convencional.

3. COMPARAÇÃO DOS ARTIGOS

A Tabela 1 mostra uma síntese comparativa dos sete métodos de controle distribuído analisados. A comparação leva em consideração o método de controle empregado, o nível de tensão da rede estudada, os benefícios que o controle proposto apresentou e o papel desempenhado pelo BESS na estratégia.

Tabela 1: Comparação dos artigos selecionados

Ref	Método	Nível de Tensão	Benefícios	Rede de Teste	Papel do BESS
[3]	Consenso	BT	Regulação de tensão; distribuição do esforço de regulação entre BESS	Rede de BT	Absorve potência ativa de forma proporcional ao seu SoC
[4]	PJ-ADMM	MT	Regulação de tensão; redução de perdas ativas; redução do <i>curtailment</i> FV	IEEE 13, 33 e 141 barras	Absorve o excedente FV (<i>curtailment</i> virtual) e injeta potência ativa nos picos de demanda noturnos
[5]	DSMPC	MT	Regulação de tensão sob incerteza de geração FV; escalabilidade	IEEE 34 barras	Absorve ou injeta potência ativa de acordo com o controlador
[6]	MADRL / MASDAC	MT	Regulação de tensão livre de modelo	IEEE 123 e 342 barras	Absorve ou injeta potência ativa de acordo com o controlador
[7]	Controle Estocástico em Dupla Camada	MT	Regulação de tensão em dois horizontes temporais (<i>day-ahead</i> e tempo real); coordenação entre OLTC, BESS e compensação de reativos dos inversores FV	Rede real 10kV, 37 barras	Absorve ou injeta potência ativa conforme agendamento diário ótimo (Nível 1) e reativa conforme controle Nível 2.
[8]	FLC	BT	Regulação de tensão e frequência (V/f); redução da degradação das baterias	IEEE 33 barras	Absorve ou injeta potência ativa e reativa de acordo com regras fuzzy; dividido em grupos A/B por nível de SoC para evitar micro-ciclos
[9]	MCTS-RL + MPC (CSOCC)	BT / MT	Regulação de tensão; aumento virtual da capacidade dos	IEEE 33 barras e rede real de 25kV	BESS de regiões assistentes compensam capacidade

			BESSs; diminuição custos de energia		insuficiente das regiões impactadas
--	--	--	---	--	---

Da Tabela 1, observa-se que a maioria dos artigos, com exceção de [3], incluem em sua análise as redes de média tensão, demonstrando sua relevância para a realização deste Projeto de Formatura (PF), que também se concentrará em redes de distribuição de média tensão. Além disso, todos eles demonstram como consequência da estratégia de controle empregada a regulação de tensão, entre outros benefícios, como a distribuição do esforço de regulação entre BESS [3] e a redução da degradação das baterias [8], por exemplo. Ademais, a maioria demonstrou robustez por meio de testes em redes padrão do IEEE, com exceção de [3], cuja simulação foi feita em rede não especificada, e [7], cuja simulação foi feita em uma rede real de 10 kV e 37 barras, similar às redes IEEE utilizadas nos outros artigos. Em relação ao papel desempenhado pelo BESS, pode-se dizer que, em todas as estratégias, ele injeta ou absorve a potência comandada pelo controle, ou seja, serve como uma ferramenta para o sistema de controle agir para regular a tensão.

4. CONCLUSÕES

Em síntese, a revisão bibliográfica realizada evidenciou as estratégias de controle distribuído de BESS utilizadas na literatura, como são empregadas e seu desempenho em relação à regulação de tensão e outros benefícios proporcionados à rede elétrica. No contexto deste PF, o artigo [3] se destaca por tratar de controle por algoritmo de consenso, que será empregado no trabalho, provando a eficácia dessa estratégia em distribuir o esforço da regulação de tensão de forma equitativa entre os BESSs da rede. Ademais, o artigo [7] se relaciona com o trabalho a ser realizado neste PF, uma vez que emprega o método Monte Carlo para gerar cenários diários de geração fotovoltaica, similar à geração de cenários envolvendo a taxa de crescimento dos sistemas fotovoltaicos e BESS nos próximos 5 e 10 anos, taxa de crescimento da demanda, áreas geográficas mais prováveis para a instalação de SFV e BESS, entre outras variáveis.

De forma geral, os artigos apresentam lacunas que este projeto de formatura pretende preencher, demonstrando inovação em relação à literatura atual. Por exemplo, os trabalhos revisados não analisam o desempenho das estratégias de controle distribuído em redes trifásicas desequilibradas, apesar de [7] e [9] citarem

essa possibilidade para trabalhos futuros. Além disso, os artigos, com exceção de [8], não levam em conta a degradação das baterias para realizar o controle distribuído. Este PF se beneficiaria ao utilizar uma abordagem similar à utilizada em [8] para, além de inserir o ciclo de vida no modelo de BESS, incluí-lo na estratégia de controle. Assim, após a realização da revisão bibliográfica de estratégias de controle (Subetapas 1.1 e 1.2 do Plano de Trabalho do PF), o próximo passo é realizar a configuração do ambiente de simulação, integrando Python ao software OpenDSS, para realizar fluxos de potência iterativos.

BIBLIOGRAFIA

- [1] STECCA, M. et al. A comprehensive review of the integration of battery energy storage systems into distribution networks. *IEEE Open Journal of the Industrial Electronics Society*, v. 1, n. 1, p. 46–65, 2020.
- [2] PARADA CONTZEN, M. A distributed double-layer control algorithm for medium voltage regulation and state of charge consensus of autonomous battery energy storage systems in distribution networks. *Journal of Energy Storage*, v. 103, p. 114314, 10 dez. 2024.
- [3] XING, L. et al. Distributed Voltage Regulation for Low-Voltage and High-PV-Penetration Networks with Battery Energy Storage Systems Subject to Communication Delay. *IEEE Transactions on Control Systems Technology*, v. 30, n. 1, p. 426–433, 1 jan. 2022.
- [4] FAR, S. R. et al. ADMM-Based Multi-Objective Control Scheme for Mitigating the Impact of High Penetration DER Integration in the Modern Distribution Systems. *IEEE Access*, v. 11, p. 38589–38603, 2023.
- [5] MA, C. et al. Distributed MPC-Based Voltage Control for Active Distribution Networks Considering Uncertainty of Distributed Energy Resources. *Electronics (Switzerland)*, v. 13, n. 14, 1 jul. 2024.
- [6] CAO, D. et al. Data-Driven Multi-Agent Deep Reinforcement Learning for Distribution System Decentralized Voltage Control with High Penetration of PVs. *IEEE Transactions on Smart Grid*, v. 12, n. 5, p. 4137–4150, 1 set. 2021.
- [7] EMARATI, M. et al. A two-level over-voltage control strategy in distribution networks with high PV penetration. *International Journal of Electrical Power & Energy Systems*, v. 130, p. 106763, 1 set. 2021.
- [8] LIU, W. et al. Optimal fuzzy logic control of energy storage systems for V/f support in distribution networks considering battery degradation. *International Journal of Electrical Power & Energy Systems*, v. 139, p. 107867, 1 jul. 2022.
- [9] AL-SAFFAR, M.; AL-SAFFAR, M.; MUSILEK, P. Reinforcement Learning-Based Distributed BESS Management for Mitigating Overvoltage Issues in Systems with High PV Penetration. *IEEE Transactions on Smart Grid*, v. 11, n. 4, p. 2980–2994, 1 jul. 2020.

- [10] QIU, C. et al. Distributed optimization for the trade-off between state-of-charge balancing and strategic battery usage in a networked BESS. *Journal of Energy Storage*, v. 105, p. 114550, 1 jan. 2025.
- [11] ZHAO, T.; PARISIO, A.; MILANOVIC, J. V. Distributed Control of Battery Energy Storage Systems for Improved Frequency Regulation. *IEEE Transactions on Power Systems*, v. 35, n. 5, p. 3729–3738, 1 set. 2020.
- [12] ZHAO, T.; PARISIO, A.; MILANOVIĆ, J. V. Distributed control of battery energy storage systems in distribution networks for voltage regulation at transmission–distribution network interconnection points. *Control Engineering Practice*, v. 119, p. 104988, 1 fev. 2022.